# UNIVERSITÉ DE STRASBOURG INTELLIGENCE ARTIFICIELLE

# Licence 3 Informatique

# Sujet 4 – Apprentissage de représentations par reconstruction

Modèle fondamental : réseau de neurones artificiels

# A. Objectif

Pour ce sujet, votre objectif est de mettre en œuvre et d'évaluer un réseau de neurones artificiels un peu particulier : ce modèle devra apprendre à reconstruire ses propres entrées. Pour des données de dimension d, il s'agira donc d'apprendre à représenter ces données en dimension d' (avec d' d), et la « représentativité » de ces d' dimensions sera évaluée en reconstruisant les d dimensions à partir des d' dimensions apprises.

#### B. Travail à réaliser

L'apprentissage réalisé dans ce sujet est **non-supervisé**, vous ne ferez donc pas usage des étiquettes des données.

# 1) Construire le modèle de représentation et reconstruction

En utilisant le code développé en TP, mettez en œuvre un réseau de neurones artificiels ayant trois couches cachées contenant respectivement 16, 8, et 16 unités. Les couches d'entrée et de sortie sont toutes deux de dimension d. On a donc ici d' = 8.

#### 2) Entraînement du modèle

- Les données devront être normalisées entre -1 et +1.
- Les couches cachées et de sorties seront activées avec tanh.
- L'erreur du modèle sera calculée avec la fonction d'erreur quadratique moyenne (mean square error), et la formule de calcul de gradient à la couche de sortie du modèle est :  $2/d \left|A^{[L]} y\right| \times \left|1 A^{[L]2}\right|$

Entraînez votre modèle pendant 200 époques, avec  $\eta = 0.01$ .

### 3) Exploration de la représentation apprise

 Sélectionnez les 50 % d'instances pour lesquelles l'erreur de reconstruction est la plus faible, et extrayez leur représentation comprimée du modèle pour obtenir un sous-jeu de données encodé. 2. Appliquez une ACP¹ sur les données encodées et visualisez les.

# 4) Évaluation des reconstructions

- 1. Définissez des métriques telles que l'erreur moyenne de reconstruction et son écart type, par instance, par attribut, et  $par\ classe^2$ .
- 2. Calculez ces erreurs sur l'ensemble du jeu de données encodé et visualisez les (par exemple au moyen de diagrammes en barres). Y a-t-il des attributs systématiquement moins bien reconstruits que d'autres ?
- 3. Sélectionnez quelques instances et comparez les à leur reconstruction.

# 5) Influence de d' sur la qualité de la reconstruction

- 1. Entraı̂nez deux autres modèles, l'un avec d'=12 et l'autre avec d'=4.
- 2. Utilisez les métriques précédemment définies pour comparer les erreurs de reconstruction de vos trois modèles.
- 3. Discutez l'idée de recherche d'un compromis entre le taux de compression des données et la fidélité de la reconstruction.

# 6) Conclusion réflexive

- 1. Discutez des intérêts à encoder des données en réduisant leur dimension.
- 2. Quelles contraintes peuvent rendre l'approche que vous avez mise en œuvre peu pratique ou avantageuse ?

# C. Items à évaluer

- 1. Extraire aléatoirement une instance du jeu de test et illustrez sa compression et sa reconstruction par votre modèle.
- 2. En utilisant vos métriques d'évaluation, illustrez quelle classe est la plus compliquée à reconstruire par votre modèle.
- 3. En comparant l'exactitude d'entraînement et de validation d'un de vos modèles, indiquez si le modèle a sur-appris (expliquez votre réponse).
- 4. Sélectionnez deux instances dont les encodages sont proches, et expliquez si cette similarité fait sens.
- 5. Sélectionnez quelques instances et comparez les avec leurs forme reconstruite. Soulignez les deux attributs donnant lieu aux erreurs de reconstruction les plus importantes.

<sup>1</sup> Pas besoin de coder une ACP à la main: vous pouvez utiliser scikit-learn.

<sup>2</sup> Rappelez vous que les données que vous utilisez sont étiquetées, même si ces étiquettes ne sont pas utilisées dans l'apprentissage du modèle.

- 6. Montrez la visualisation l'erreur de reconstruction moyenne (a) des classes et (b) des attributs.
- 7. Montrez la visualisation de vos données encodées après ACP.
- 8. Comparez les performances de reconstruction de deux de vos modèles. Expliquez en quoi d' influence la qualité de la reconstruction.